

멀티모달 발음·독화 평가를 중심으로 한
한국어 독화 학습 플랫폼 LIPLAB의 고도화

청각장애 학습자를 위한 AI 독화·발화 훈련 시스템
Advancing LIPLAB, a Korean Speechreading Platform

고 도 화 계 획 서

CNSAi

남윤수 · 최윤건 · 나현빈 · 염우진 · 황성주

충남삼성고등학교

2026. 08. 25.

국 문 요 약

멀티모달 발음·독화 평가를 중심으로 한 한국어 독화 학습 플랫폼 LIPLAB의 고도화

LIPLAB은 일반학교에 재학하는 청각장애 학습자를 위한 한국어 독화(讀話)·발화(發話) 훈련 웹 플랫폼이다. 초기 문장 독화 연습 도구에서 출발하여 독화·발화·수어·촉각의 네 축과 다섯 단계 커리큘럼을 갖춘 학습 플랫폼으로 확장되었다.

본 계획서는 현행 시스템의 기술적 한계를 진단하고 그 해소를 위한 고도화 방안을 제시한다. 가장 근본적인 문제는 발화 발음평가가 자동음성인식(ASR) 전사에 의존한다는 점이다. 현행 평가는 사용자의 음성을 텍스트로 전사한 뒤 채점하는데, 이 기능의 주 사용자는 정상 발화로 학습된 ASR이 발음을 자주 오인식하는 농인·난청 화자이다. 채점의 정확도가 전사 오류에 종속되는 구조적 모순이 존재한다.

이를 해소하기 위하여 본 고도화는 전사 단계를 거치지 않고 음향과 영상에서 발음·조음을 직접 평가하는 방향으로 시스템을 재구성한다. 구체적으로 열한 개의 고도화 축을 설정한다. 소리·영상·글자를 함께 이해하는 통합 모델과 그 학습을 위한 농인 발화 합성(A), 전사 비의존 발음채점과 오디오·비주얼 융합(B), 데이터 기반 채점과 공개 표준 리소스 구축(C), 웹캠 입모양 채점과 자체 립리딩 모델(D), 조음 원인 진단과 조음 시뮬레이터(E), 실사·투명 아바타 시연(F), 콘텐츠 대량화와 개인화(G), 다자 대화 실전 시나리오(H), 디지털 독화 표준검사(I), 안 보이는 소리의 시각 증강(J), 입술 너머 확장 조음 단서(K)이다. 열한 축은 개발과 훈련, 평가를 함께 다룬다. 그중 대표 기여는 전사에 의존하지 않는 오디오·비주얼 발음평가(축 A·B)이며, 나머지 축은 이를 둘러싼 학습·검증 생태계이다. 예비 분석에서 한국어 자음이 시각 자질만으로 네 개의 혼동 군으로 뭉침을 확인하여, 데이터 기반 채점(축 C)의 방향을 뒷받침하였다.

자원은 하드웨어 제작과 인건비를 제외하고, 소프트웨어와 3차원 자산, 인공지능 연산, 데이터에 집중하여 편성한다. 접근성 소외가 큰 한국어 독화 교육 영역에서 실증 가능한 학습 도구로 고도화하는 것이 본 계획의 목표이다.

핵심되는 말: 독화, 발음평가, GOP, 오디오·비주얼 융합, 청각장애, 자기지도학습, 접근성

차 례

국문 요약.....	2
제1장 서론.....	7
1.1 연구 배경 및 필요성.....	7
1.2 기존 개발 성과.....	8
1.3 고도화의 문제의식.....	9
1.4 고도화 목표 및 범위.....	9
제2장 현행 기술 및 시스템 분석.....	11
2.1 독화와 발화 재활의 배경.....	11
2.2 현행 LIPLAB 시스템 구조.....	11
2.3 현행 앱의 기능 정의.....	12
2.4 현행 화면 구성 및 흐름.....	13
2.5 발음평가 기술의 검토.....	14
2.6 현행 시스템의 한계와 미해결 이슈.....	15
2.7 예비 분석과 구현·실증.....	16
제3장 고도화 방안.....	23
3.1 통합 멀티모달 AI와 농인 발화 합성 (A).....	24
3.2 전사 비의존 발음채점과 오디오·비주얼 융합 (B).....	25
3.3 데이터 기반 채점과 공개 표준 리소스 (C).....	26
3.4 웹캠 입모양 채점과 자체 립리딩 모델 (D).....	27
3.5 조음 원인 진단과 조음 시뮬레이터 (E).....	27
3.6 실사·투명 아바타 시연 (F).....	28
3.7 콘텐츠 대량화 및 개인화 (G).....	29
3.8 다자 대화·실전 시나리오 독화 (H).....	29
3.9 디지털 독화 표준검사 (I).....	29

3.10 안 보이는 소리의 시각 증강 (J).....	30
3.11 입술 너머 확장 조음 단서 (K).....	31
제4장 구현 및 추진 계획.....	32
4.1 시스템 아키텍처.....	32
4.2 데이터 및 학습 계획.....	33
4.3 구매 자산 활용 방안.....	34
4.4 추진 전략 및 단계.....	34
4.5 추진 일정.....	35
4.6 추진 체계 및 역할.....	35
4.7 당사자 파일럿 및 연구윤리.....	36
4.8 위험요인 및 대응.....	36
4.9 보안 취약점 및 대응.....	37
제5장 예산 및 조달 계획.....	38
5.1 편성 원칙.....	38
5.2 구매 명세.....	38
5.3 Claude Max 배정.....	39
5.4 무료 확보 자원 및 집행 우선순위.....	40
제6장 기대효과 및 활용 방안.....	41
참고문헌.....	43
ABSTRACT.....	45
 그 립 · 표 차 례 	
<그림 1> 고도화 축 구성.....	10
<그림 2> 현행 앱의 화면 이동 흐름.....	14
<그림 3> 현행 대 제안 발음평가 파이프라인.....	16

<그림 4> 예비 분석: 자음 시각 혼동과 지각공간.....	17
<그림 5> 예비 구현: 독화 난이도 자동 산출.....	18
<그림 6> 예비 실증: 전사 없이 산출한 음소별 발음 신뢰도.....	18
<그림 7> 예비 실증: 저하 강도별 전사 오류와 음향 불확실성.....	19
<그림 8> 한국어 예비 실증: 문맥 발화의 확신 오전사.....	20
<그림 9> 예비 실증: 웹캠 계열 랜드마크의 입모양 수치화.....	21
<그림 10> 예비 구현: 난이도 기반 자동 배치검사 문항.....	22
<그림 11> 전사 비의존 오디오·비주얼 발음평가 구조.....	26
<그림 12> 시스템 데이터 흐름.....	33
<표 1> 선행 및 유사 도구와의 비교.....	8
<표 2> 현행 LIPLAB 시스템의 구성 모듈.....	12
<표 3> 현행 앱의 기능 정의.....	12
<표 4> 현행 주요 화면과 역할.....	13
<표 5> 발음평가 방식의 비교.....	15
<표 6> 고도화 축의 요약.....	23
<표 7> 신규 및 교체 구성요소.....	32
<표 8> 구매 자산의 활용 방안.....	34
<표 9> 추진 일정.....	35
<표 10> 주요 위험요인 및 대응.....	36
<표 11> 보안·개인정보 취약점과 대응.....	37
<표 12> 구매 명세 (예산 조달 계획).....	38

제 1 장 서론

1.1 연구 배경 및 필요성

청각장애 학생의 상당수는 특수학교가 아닌 일반학교에서 청인(聽人) 또래와 함께 수학한다. 국립특수교육원의 특수교육통계(2020)에 따르면 청각장애 학생의 약 57퍼센트가 일반학교에 재학하는데, 이는 청각장애 학생 다수가 수어 중심의 환경이 아니라 한국어 음성언어가 오가는 환경에서 하루의 대부분을 보낸다는 뜻이다. 이러한 환경에서 이들은 수업 설명과 친구들과의 대화, 교내 안내처럼 소리로 전달되는 정보의 상당 부분을 상대의 입모양과 표정, 그리고 앞뒤 문맥에 기대어 이해한다. 그럼에도 정작 그 독화를 체계적으로 가르치는 정규 교육과정은 사실상 존재하지 않는다. 대부분의 학습은 학교의 지원 없이 개인의 자율적 노력과 가정의 사정에 맡겨져 있으며, 그 결과 같은 청각장애라 하더라도 독화 능력의 편차가 크게 벌어진다.

독화는 그 자체로 본질적인 한계를 가진다. 한국어의 여러 음소는 입 밖으로 드러나는 조음 형태가 서로 동일하거나 매우 유사하여 시각만으로는 구별되지 않는다. 예를 들어 양순음 ㅂ, ㅍ, ㅁ은 두 입술을 붙였다 떼는 동작이 서로 같아, 눈으로는 어느 소리가 났는지 가려내기 어렵다. 이렇게 입모양이 같아 시각적으로 변별되지 않는 음소의 무리를 동구형이음(同口形異音)이라 한다. 이 때문에 아무리 숙련된 독화자라도 입모양만으로 모든 말을 완전히 읽어 낼 수는 없으며, 보이지 않는 소리를 앞뒤 맥락으로 메우는 추론 전략을 함께 익혀야 한다. 결국 독화 학습은 보이는 것을 정확히 가려내는 지각 능력과, 보이지 않는 것을 문맥으로 짐작하는 추론 능력을 동시에 요구하는 셈이다. 그러나 이러한 한국어 독화를 특화하여 다루는 디지털 학습 도구는 국내에 거의 없으며, 기존 자원은 촬영된 영상 강의와 대면 지도, 범용 언어 학습 앱 정도에 그친다. 영상 강의는 상호작용과 개인화가 없고, 대면 지도는 비용과 접근성의 제약이 크며, 범용 앱은 한국어 독화의 음운적 특수성을 다루지 못한다.

국내외 유사 도구를 살펴보면(표 1), 한국어 독화를 특화한 성숙한 디지털 도구는 사실상 없다. 국내 사례는 발화 교정이나 모음·큐 보조에 국한된 학술 프로토타입이고, 성숙한 독화 훈련 서비스는 모두 영어권이라 한국어 음운과 입모양 특성을 반영하지 못한다. 전사에 기대지 않고 음성과 입모양을 함께 평가하거나 실시간으로 콘텐츠를 생성·개인화하는 접근은 연구 단계에만 존재하며, 한국어 청각장애 학습을 겨냥한 완성 도구는 확인되지 않는다.

<표 1> 선행 및 유사 도구와의 비교

도구	대상·언어	방식	한계 또는 차이
See&Speech (국내)	한국어·발음	전면카메라 자가 발음교정(학술)	발화 교정 중심, 독화 아님. 실시간 평가·개인화 없음
보구보구 (국내)	한국어	모음 입모양 판별(학술)	모음 단위에 국한, 문장 맥락 없음
한국 큐드스피치 앱	한국어	손신호와 입모양으로 음소 구별	큐 보조체계 학습, 자동 평가 없음
Lipreading.org	영어	웹 적응형 독화 연습	영어 전용, 한국어 음운 미반영
Articulate	영어·발음	음성인식 기반 발음 피드백	전사(ASR) 의존, 청각장애 독화 아님
PTeacher (연구)	영어·발음	오디오·비주얼 과장 교정 피드백	L2 학습 대상 연구, 상용 아님
LIPLAB (본 계획)	한국어·청각장애	실시간 생성 + 전사 비의존 AV 평가 + 개인화	위 공백을 겨냥한 한국어 특화 도구

1.2 기존 개발 성과

LIPLAB은 이러한 공백을 겨냥하여, 대규모 언어모델의 실시간 문장 생성과 음운 유사도 기반 자동 채점, 그리고 입모양의 삼차원 시각화를 하나로 결합한 학습 도구로 개발되었다. 개발이 이어지는 동안 시스템은 크게 확장되었다. 학습자가 오가는 화면은 7개에서 20개로, 프론트엔드 구성요소는 5개에서 12개로 늘었고, 삼차원 얼굴 모델은 불필요한 자원을 걷어 내고 압축하여 용량을 약 82퍼센트 줄였다. 채점 엔진은 자모 단위 정렬과 음운 유사도 행렬을 사용하며, 모음의 입모양이 가장 잘 보인다는 점을 반영하여 초성 30퍼센트, 중성 50퍼센트, 종성 20퍼센트의 가중치를 둔다. 입모양은 15종의 비침

(viseme) 분류 체계로 정리되어 있다. 나아가 시스템은 독화와 발화, 수어, 촉각의 네 축과 다섯 단계 커리큘럼을 갖추었고, 학습 자료는 13개의 데이터베이스 표로 관리된다. 다만 본 계획서의 목적은 이러한 성과를 나열하는 데 있지 않고, 아래에서 다룰 남은 기술적 과제를 해소하는 데 있다.

1.3 고도화의 문제의식


현행 시스템을 코드 수준에서 점검한 결과 다음 네 가지 한계가 확인되었다.

- **발화 발음평가의 전사 종속.** 발화 채점은 음성을 자동음성인식으로 전사한 뒤 그 텍스트를 채점한다. 그러나 이 기능의 대상은 정확히 그 자동음성인식이 잘 인식하지 못하는 화자이다. 채점이 전사 오류에 종속되는 구조적 모순이 존재한다.
- **채점 계수의 미검증.** 음운 유사도 행렬과 비심 지속시간은 저자가 수작업으로 지정한 상수이며, 실제 독화 혼동 빈도나 조음 데이터와 대조된 적이 없다.
- **콘텐츠의 알음과 당사자 검증의 부재.** 기초 단계의 학습 콘텐츠 분량이 적어 학습 경로를 충분히 채우지 못한다. 지금까지의 사용 시험은 비당사자에 국한되었다.
- **사용자 입모양 검증의 부재.** 시스템은 아바타로 입모양을 보여줄 뿐, 사용자가 그 입모양을 실제로 맞게 만드느지를 확인하지 못한다.

1.4 고도화 목표 및 범위

본 고도화의 목표는 앞에서 짚은 한계를 해소하여 LIPLAB을 실증 가능한 학습 도구로 끌어올리는 것이다. 이를 위해 그림 1과 같이 열한 개의 고도화 축을 설정한다. 이 축들은 서로 떨어진 기능의 단순한 나열이 아니라, 하나의 공유 인공지능 백본(A) 위에서 유기적으로 맞물린다. 백본 위에서 발음과 독화를 평가하고(B, C, D, E), 그 평가 결과를 학습자에게 시연하고 훈련시키며(F, G, H), 마지막으로 학습자의 성취를 검사한다(I). 여기에 입모양으로 드러나지 않는 소리를 시각으로 보완하고 그 신호를 웹캠에서 캐내는 두 축(J, K)을 더한다. 이렇게 개발과 훈련, 평가가 하나의 구조 안에서 이어지도록 설계한 점이 본 고도화의 골격이다. 이 가운데 전사 비의존 오디오·비주얼 발음평가(A·B)를 본 계획의 대표 기여로 삼고, 나머지 축은 그것을 뒷받침하고 확장하는 역할로 배치한다.

자원 운용의 범위는 소프트웨어와 삼차원 자산, 인공지능 연산, 데이터 확보로 한정한다. 촉각 학습기의 물리적 하드웨어 제작과 인건비성 지출은 본 고도화의 범위에 포함하지 않는다. 이는 한편으로 지원 자원의 성격에 따른 것이고, 다른 한편으로는 계획의 초점을 소프트웨어와 모델 연구에 두어 한정된 예산에서 기술적 성과를 최대한 끌어내려는 판단에 따른 것이다.



B~E는 A(백본) 위의 갈래 · K가 캐넌 신호를 J가 기호로 표시 · E·F는 3D 성도 자산 공유 · I는 C 자산을 문항으로

화

<그림 1> 고도화 축 구성. 공유 백본(A) 위에서 평가(B~E), 증강·감지(J·K), 시연과 훈련(F~H), 검사(I)가 개발-훈련-평가를 이룬다.

제 2 장

현행 기술 및 시스템 분석

2.1 독화와 발화 재화의 배경

독화는 청각 정보의 결손을 시각 정보로 보완하여 말을 이해하는 과정이다. 사람은 본래 소리와 입모양을 함께 통합하여 말을 지각하며, 시각 정보가 청각 지각에 영향을 미친다는 사실은 오래전부터 보고되어 왔다. 실제로 같은 소리라도 화자의 입모양이 다르면 다른 소리로 들리는 현상이 관찰되기도 한다. 그러나 앞서 언급한 동구형이음 때문에, 입모양만으로 전달될 수 있는 정보의 양에는 분명한 상한이 있다. 그래서 독화 학습은 보이는 음소를 정확히 변별하는 지각 훈련과, 보이지 않는 음소를 문맥으로 추론하는 전략 훈련을 함께 요구한다. 한편 발화 훈련의 영역에서는, 청각 되먹임이 제한된 학습자가 자신의 발성을 스스로 점검할 수 있도록 소리의 크기와 높이, 파형을 화면에 실시간으로 보여 주는 시각 되먹임이 오랫동안 정통적인 방법으로 활용되어 왔다.

2.2 현행 LIPLAB 시스템 구조

현행 독화 파이프라인은 다음과 같이 동작한다. 먼저 대규모 언어모델이 학습자의 취약 입모양을 반영하여 상황에 맞는 문장을 생성한다. 이어서 자체 구현한 한국어 발음 규칙 엔진이 그 문장을 소리 나는 대로 바꾸고, 초성과 중성, 종성을 15종의 비심 프레임으로 매핑한다. 삼차원 얼굴 아바타는 이 프레임을 순서대로 재생하여 입모양을 시연하고, 학습자가 읽어 낸 결과를 문자로 입력하면 채점 엔진이 자모 정렬과 음운 유사도를 이용하여 부분 점수를 계산한다.

현행 독화 기능은 인공지능이 생성한 문장을 규칙 기반 아바타로 정확히 시연하고, 학습자가 읽어 낸 답을 음운 유사도로 채점한다. 기계가 올바른 입모양을 보여 주고 학습자가 그것을 읽는, 독화 훈련 본연의 구조이다. 다만 학습자가 그 입모양을 실제로 맞게 재현하는지는 확인하지 못하며, 이 점은 뒤의 측 D에서 웹캠으로 보완한다.

발화 트랙만이 실제 음성인식을 사용한다. 학습자의 녹음을 오픈소스 음성인식 모델로 전사한 뒤 독화 채점 로직을 재활용하여 발음을 평가하고, 언어모델이 수치에 근거한 코칭을 제공한다. 표 2는 현행 시스템의 주요 모듈을 정리한 것이다.

<표 2> 현행 LIPLAB 시스템의 구성 모듈

모듈	기능	성격
발음 규칙·비심 엔진	한국어 문장을 발음대로 변환하여 15종 비심 프레임으로 매핑	규칙 기반
채점 엔진	자모 정렬과 음운 유사도로 부분 점수 산출	규칙 기반
삼차원 아바타	비심 프레임을 얼굴 모델의 형상 변형으로 재생	그래픽
언어모델 서비스	문장 생성, 대화, 코칭, 콘텐츠 생성	대규모 언어모델
발화 평가	음성 전사 후 음운 채점, 시각 되먹임 표시	전사 기반
커리큘럼	다섯 단계 학습 경로와 숙달 기반 진행, 간격 반복	학습 설계

2.3 현행 앱의 기능 정의

현행 LIPLAB이 실제로 제공하는 기능을 정리하면 표 3과 같다. 기능은 크게 입력을 읽어 내는 독화 축과 발음을 산출하는 말하기 축으로 나뉘며, 두 축을 커리큘럼과 복습, 분석이 감싼다. 아래 기능은 모두 현재 배포본(liplab.fly.dev)에서 동작한다.

<표 3> 현행 앱의 기능 정의

기능	설명	구분
상황별 문장 독화	언어모델이 학습자의 취약 입모양에 맞춘 문장을 생성하고 아바타가 입모양을 시연	독화 입력
음운 유사도 채점	자모 정렬과 유사도 행렬로 부분 점수 산출(초성 30·중성 50·종성 20)	채점
취약 입모양 추적	자주 틀리는 비심을 집계하여 약점을 시각화	분석
한국수어 학습 보조	한국어 문장을 한국수어와 연결하여 이해를 보조	보조
독화 커리큘럼	입모양 인지에서 단어, 문맥 추론 문장, 대화까지 단계 학습과 적응형 난이도	학습 경로
간격 반복 복습	오답 항목을 망각 곡선에 맞추어 재출제	복습


기능	설명	구분
발화 실시간 피드백	마이크 음량과 억양, 파형을 실시간으로 표시	말하기 입력
발화 채점·코칭	녹음을 전사한 뒤 음운 채점하고 언어모델이 코칭 제공	말하기 채점
발화 6단계 커리큘럼	발성에서 운율, 모음, 자음, 단어, 문장까지와 억양 방향 판정	학습 경로
학습 분석	독화와 말하기를 분리하여 혼동·추세·숙달을 집계	분석
배치·향상도 검사	초기 수준 진단과 향상도 측정	검사

2.4 현행 화면 구성 및 흐름

학습자가 오가는 화면은 대시보드를 중심으로 독화와 말하기 두 갈래로 뻗는다. 전체는 약 스무 개의 화면으로 이루어지며, 주요 화면과 역할은 표 4와 같고 화면 사이의 이동 흐름은 그림 2와 같다.

〈표 4〉 현행 주요 화면과 역할

화면	역할
대시보드	학습 현황과 독화·말하기 두 축의 진입점
독화 학습	상황별 문장 독화와 채점
독화 테스트	학습 성취 확인
복습	간격 반복으로 오답 재학습
입모양 인지	비심 단위의 기초 인지 훈련
단어 단계	음절과 단어 독화
문맥 추론 문장	부분 관찰로 문장 완성
대화 채점	대화 맥락에서의 독화 평가
말하기 연습	실시간 음량·억양 피드백
발화 단계	발성부터 문장까지 여섯 단계
수어 번역	한국어에서 한국수어로 보조
학습 분석	독화·말하기 분리 통계
배치검사	초기 수준 진단과 배치
학습 가이드	독화 전략 코칭



<그림 2> 현행 앱의 화면 이동 흐름. 대시보드에서 독화와 말하기 두 갈래로 나뉘고, 배치검사·복습·분석이 이를 감싼다.

화면 흐름은 배치검사로 수준을 가늠한 뒤 각 축의 단계 학습으로 들어가고, 복습과 분석이 학습 전체에 걸쳐 이어지는 구조이다.

2.5 발음평가 기술의 검토

발음의 정확도를 자동으로 평가하는 방식은 크게 두 갈래로 나뉜다. 첫째는 전사 기반 방식으로, 음성을 먼저 텍스트로 옮긴 뒤 그 텍스트를 목표 문장과 비교한다. 구현이 간단하다는 장점이 있지만, 전사 단계에서 생긴 오류가 그대로 채점으로 전달된다는 약점이 있다. 특히 정상 발화로 학습된 음성인식은 발음이 불명확한 화자를 자주 잘못 알아듣기 때문에, 정작 발음 훈련이 가장 필요한 학습자에게서 평가가 가장 불안정해지는 문제가 생긴다.

둘째는 음향 직접 방식으로, 전사를 거치지 않고 음향에서 음소 단위 발음정확도를 직접 산출한다. 대표적 지표가 GOP(Goodness of Pronunciation)이며, 이는 특정 음소가 발음된 구간의 음향이 그 음소의 표준에 얼마나 부합하는지를 확률로 수치화한다. GOP는 확립된 개념이지만 표준적 GOP는 정상 발화로 학습된 음향 모델을 전제하며, 비정형

발화에서는 과신하는 경향이 보고되었다. 최근 연구는 불확실성 정량화로 이 과신을 보정하며, 한국어를 포함한 비정형 발화에서 개선을 보고하였다. 다만 이 근거들은 주로 마비말장애 발화에서 얻은 것이므로, 농인·난청 발화로의 전이 여부는 본 계획이 당사자 파일럿으로 확인할 가정으로 둔다. 아울러 대량 음성으로 사전학습한 자기지도 표현이 소량의 라벨만으로도 음소 구조를 잘 포착하는 것으로 알려져, 데이터가 부족한 영역의 발음평가 기반으로 적합하다. 표 5는 세 방식을 비교한 것이다.


〈표 5〉 발음평가 방식의 비교

구분	전사 기반(현행)	표준 GOP	제안 방식
전사 필요	필요	불필요	불필요
음소 단위 평가	간접	직접	직접
농인 발화 적합성	낮음	미검증	보정으로 지향
시각 정보 활용	없음	없음	웹캠 입모양 융합

2.6 현행 시스템의 한계와 미해결 이슈

이상을 종합하면, 현행 시스템의 발화 평가는 전사 기반 방식이 가진 약점을 그대로 안고 있다. 그림 3은 현행 파이프라인과 본 계획이 제안하는 파이프라인을 나란히 대비한 것이다. 현행 방식에서는 음성인식 전사가 파이프라인 한가운데에 놓여 있어, 대상 화자의 발화가 한 번 잘못 인식되면 그 뒤의 채점 전체가 함께 흔들린다. 반면 제안 방식은 이 전사 단계를 아예 제거하고 음향과 영상에서 발음을 직접 평가하므로, 오인식에 종속되지 않는다.

현행: 전사(ASR) 종속 발음평가



제안: 전사 비의존 · 오디오 · 비주얼 융합 평가




<그림 3> 현행(전사 종속) 대 제안(전사 비의존·오디오·비주얼 융합) 발음평가 파이프라인.

미해결 이슈. 현행 시스템에 남은 미해결 과제는 다음과 같이 요약된다. 첫째, 발화 채점이 전사에 종속되어 정작 대상 화자에게서 가장 불안정하다. 둘째, 채점의 음운 유사도 계수가 실제 혼동 데이터로 검증되지 않은 손지정 상수이다. 셋째, 학습자가 목표 입모양을 실제로 맞게 재현하는지 확인하지 못한다(웹캠 미활용). 넷째, 농인·난청 발화 코퍼스가 없어 전용 모델을 학습하지 못했다. 다섯째, 자체 립리딩 모델과 표준화된 독화 검사가 아직 없고 기초 단계의 콘텐츠 분량이 얇다. 본 고도화의 각 축은 이 이슈들에 하나씩 대응하도록 설계하였다.

2.7 예비 분석과 구현·실증

고도화에 앞서 문제의 구조를 자체적으로 확인하기 위한 예비 분석을 수행하였다. 한국어 자음 열아홉 개를 입 밖으로 드러나는 시각 자질(양순 폐쇄, 입술 벌림, 혀끝 노출, 후방 조음의 비가시성)만으로 벡터화하고, 자음 쌍의 시각 유사도를 계산하였다. 이는 데이터로 학습하기 전 단계의 규칙·자질 기반 예비판으로, 축 C가 지향하는 지각 공간의 방향이 타당한지 가늠하기 위한 것이다.




〈그림 4〉 예비 분석. 시각 자질 기반 한국어 자음 혼동도(좌)와 시각 지각공간(우, 고전 MDS). 데이터 학습 전 규칙·자질 기반 예비 결과이다.

결과는 그림 4와 같이 자음이 네 개의 시각 군으로 뚜렷이 뭉침을 보였다. 양순음(ㅂ·ㅍ·ㅁ 등)은 서로 거의 구분되지 않고, 연구개·성문음(ㄱ·ㅋ·ㅇ·ㅎ 등)은 조음이 입 안쪽이라 대부분 하나로 붕괴한다. 즉 동구형이음의 상당 부분이 시각 자질만으로도 재현된다. 이 예비 결과는 두 가지를 시사한다. 첫째, 독화의 어려움이 특정 음소 군에 집중되어 있어 학습과 채점의 우선순위를 부여할 수 있다. 둘째, 시각 유사도 공간이 이미 알려진 혼동 군을 복원하므로, 이를 실제 시청각 데이터로 학습해 채점 근거로 삼는 축 C의 접근에 근거가 있음을 보여준다.


나아가 이 지각 구조를 실제 도구로 구현하여 실행하였다. 한국어 단어를 자모로 분해하고 각 음소를 시각 군으로 매핑하는 프로토타입을 작성하여, 첫째로 입모양이 동일해 문맥 없이는 구분되지 않는 단어 무리를 자동으로 찾고, 둘째로 임의의 단어와 구에 독화 난이도 지수를 부여하였다.

자동 탐지 결과, {가·카·하·아}, {다·타·나·사}, {바·파·마}, {달·탈·날·살}, {물·불·풀}, {밤·팜·맘}처럼 실제로 입모양이 같은 무리가 그대로 검출되었다. 난이도 지수는 그림 5와 같이 연구개·성문음이 많은 ‘공항·학교·항구’를 어렵게, ‘나비·바다’를 쉽게 매겨 직관과 일치하는 순위를 보였다. 이는 축 C의 핵심(동구형이음 사전과 난이도 지수)이 규칙 기반 수준에서 이미 작동함을 보인 것으로, 이후 실제 시청각 데이터로 학습하여 정밀화하는 방향의 출발점이 된다.



<그림 5> 예비 구현 실행 결과. 자모를 비침으로 분해하는 프로토타입이 산출한 한국어 단어·구의 독화 난이도 지수(규칙 기반 프로토타입의 실제 출력).


발음(음향) 쪽에서도 같은 방향의 예비 실증을 수행하였다. 공개 낭독 음성(LibriSpeech)에 저역통과와 잡음을 더해 발화가 불명료해진 상황을 모사하고, 공개 자기지도 음성모델로 전사(ASR) 결과와 전사를 거치지 않은 음소별 발음 신뢰도를 각각 산출해 비교하였다.



<그림 6> 예비 실증 실행 결과. 공개 낭독 음성을 뭉갠 때 전사(ASR)는 단어를 틀리지만, 전사 없이 산출한 음소 신뢰도는 약해진 음소만 국소적으로 낮아진다.

그림 6과 같이 발화가 뭉개지자 전사는 문장 앞부분의 단어를 틀렸다. ‘mister quilter’가 ‘if the quoter’로 바뀐 것이다. 반면 전사를 거치지 않고 산출한 음소 신뢰도는 전반적으로 유지되면서 약해진 음소만 국소적으로 낮아졌다(예: /s/ 0.92에서 0.71, /ð/ 0.83에서 0.65). 전사 기반 채점은 한 번의 오인식이 단어 전체를 무너뜨리는 반면, 음소 단위 직접 산출은 저하를 국소적이고 연속적으로 반영한다. 규칙·소규모 수준의 실증이지만, 축 A·B가 내세우는 전사 비의존 발음평가가 실제로 성립함을 보여준다.

나아가 저하를 한 번이 아니라 강도별로 높여 가며, 전사와 전사 없는 음향 지표가 저하에 어떻게 반응하는지 비교하였다.



실제 저하 구간(1→4)에서 두 불확실성 지표는 완만·연속으로 상승, ASR 오류는 한 번에 된 뒤 포화한다. (레벨1의 미세 개선은 약한 평활의 잡음 제거 효과)

<그림 7> 예비 실증 실행 결과(영어 실음성). 저하 강도를 높이면 전사 오류(WER)는 계단식으로 급변한 뒤 포화하지만, 전사 없이 얻은 음향 불확실성은 점진적·연속적으로 상승한다.

그림 7과 같이 전사 오류는 저하가 일정 수준을 넘는 순간 한 번에 커진 뒤 더 나빠지지 못하고 포화하여, 발음이 얼마나 무너졌는지의 정도를 구분하지 못한다. 반면 전사를 거치지 않은 음향 불확실성(사후확률의 엔트로피, 상위 후보 간 확신 마진의 감소)은 저하 강도에 따라 완만하고 연속적으로 커진다. 가장 약한 저하 구간에서 값이 미세하게 개선되는 지점이 있는데, 이는 약한 평활이 잡음을 일부 제거한 효과로 해석된다. 발음 채점이 정도의 차이를 반영해야 함을 고려하면, 이러한 연속적 반응은 전사 기반 판정보다

음향 직접 측정이 채점에 적합함을 뒷받침한다. 다만 원점수 확신의 거동은 입력 품질에 따라 달라지므로, 축 B에서는 이를 불확실성으로 보정하여 사용한다.

같은 확인을 한국어에서도 수행하였다. 한국어 문장을 음성으로 합성한 뒤 발화를 뭉개는 강도를 다섯 단계로 높이며, 공개 한국어 음성인식 모델로 전사를 시도하였다.

원문(한국어 음성 합성): “공항에서 친구를 만났어요” 전사 모델: kresnik/wav2vec2-xlsr-korean

뭉개 강도	ASR 전사 결과	CER
0 (명료)	“공항에서 친부를 만났어요”	27%
1	“공항에서 친구를 만났어요”	18%
2	“앞에서 승부를 남겼어요”	61%
3	“일로우에서 쓴부이 안났어요”	56%
4 (심함)	“일로난에서 선들이 안졌어요”	65%

<그림 8> 한국어 예비 실증 실행 결과. 발화가 뭉개질수록 전사는 실패를 드러내지 않고 문장을 다른 실제 단어들로 자신 있게 바꾸어 놓는다.


그림 8에서 보듯 전사는 발화가 뭉개져도 무음이나 공백으로 실패를 드러내지 않고, 매번 문장을 문법적으로 그럴듯한 다른 실제 단어들로 바꾸어 놓았다. ‘공항에서 친구를 만났어요’는 명료한 합성음에서도 ‘공항에서 친부를 만났어요’가 되었고, 뭉개기가 심해지자 ‘일로난에서 선들이 안졌어요’처럼 원문과 무관한 실제 단어열로 재작성되었다. 이러한 조용한 확신 오류는 전사 텍스트를 채점 기준으로 삼는 방식이 안고 있는 위험을 드러낸다. 정작 음성인식이 취약한 비정형 발화일수록, 그럴듯하지만 틀린 기준이 만들어져 학습자에게 그대로 전달되기 때문이다.

한편 같은 실험에서 음향 신뢰도를 단순 최대사후확률로 산출하면, 발화가 뭉개질수록 값이 오히려 높아지는 구간이 관찰되었다. 모델이 소수의 음소로 과도하게 확신하며 붕괴하는 현상이다. 이는 원점수 확신을 그대로 채점에 쓸 수 없음을 보여주며, 축 B에서 음소 신뢰도를 예측 분산과 여유값으로 보정하는 D-GOP 설계가 필요한 직접적 근거가 된다.

영상 채점의 실현 가능성도 점검하였다. 웹캠 계열 파이프라인으로 입모양을 수치화할 수 있는지 보기 위해, 딥러닝 얼굴 랜드마크 검출기로 얼굴에서 예순여덟 개의 특징점을 추출하고 입술 스무 점의 좌표에서 가로 너비와 개구도, 종횡비, 입술 둘레를 산출하였다. 화자마다 다른 얼굴 크기의 영향을 없애기 위해 모든 값을 양안 거리로 정규화하였다. 프라이버시를 위해 실존 인물이 아닌 합성 얼굴로 실행하고, 문서에는 비식별 좌표만 실는다.

(b) 입술 좌표에서 산출한 입모양 지표

(a) 추출된 얼굴 랜드마크 68점 (입술 20점 강조, 비식별)



지표	값 (양안거리 정규화)
가로 너비	0.816
바깥 세로높이	0.273
안쪽 개구도	0.044
종횡비 (세로/가로)	0.335
입술 둘레 (정규화)	1.813

<그림 9> 웹캠 계열 얼굴 랜드마크로 입모양을 수치화한 실행 결과. 입술 좌표에서 스케일 불변 지표가 안정적으로 산출된다(합성 얼굴, 비식별 좌표).

그림 9와 같이 입모양이 얼굴 크기에 무관한 수치로 안정적으로 표현되었다. 이 지표들은 목표 발음의 입모양 원형과 대조되어, 측 D의 웹캠 입모양 채점과 음향·영상 후기 융합(그림 11)에서 영상 측 근거로 쓰인다.

끝으로 측 I의 표준검사를 자동으로 구성할 수 있는지 살펴보았다. 앞서 얻은 독화 난이도 지수로 단어 은행을 다섯 등급으로 나누고, 각 문항에 안 보이는 후방음의 비율과 입모양이 겹치는 충돌 단어를 자동으로 태깅하였다.

등급 / 난이도	예시 문항	자동 진단 포인트
Lv1 입문 지수 4.0 - 6.3	배	(4.0) 가시 단서 충분
	이마	(6.0) 안 보이는 후방음 50%
	오이지	(6.3) 안 보이는 후방음 66%
Lv2 기초 지수 6.7 - 7.5	까마귀	(6.7) 안 보이는 후방음 66%
	오리	(7.5) 안 보이는 후방음 50% · 입모양 충돌 '유리'
	불러요	(7.5) 가시 단서 충분
Lv3 표준 지수 8.0 - 8.0	아이	(8.0) 안 보이는 후방음 100%
	거기	(8.0) 안 보이는 후방음 100%
	먹어요	(8.0) 안 보이는 후방음 66%
Lv4 심화 지수 8.2 - 9.3	노래를	(8.2) 가시 단서 충분
	깎두기	(9.0) 안 보이는 후방음 66%
	학교에	(9.3) 안 보이는 후방음 100%
Lv5 도전 지수 9.5 - 12.0	강충강충	(9.5) 안 보이는 후방음 50%
	국가	(10.0) 안 보이는 후방음 100%
	공항	(12.0) 안 보이는 후방음 100%

〈그림 10〉 난이도 지수로 자동 생성한 적응형 배치검사 문항 세트. 등급별 문항과 함께 안 보이는 후방음 비율·입모양 충돌 같은 진단 정보가 자동으로 붙는다.

그림 10은 그 실행 결과로, 입문에서 도전까지 다섯 등급의 문항이 진단 정보와 함께 자동 생성되었다. ‘공항·국가’처럼 안 보이는 후방음이 전부인 항목이 최상위 난이도로, ‘배’처럼 가시 단서가 충분한 항목이 최하위로 배치되었다. 문항이 사람의 수작업 없이 난이도 순으로 구성되고 각 항목이 무엇을 측정하는지 함께 제시되므로, 축 I의 적응형 배치검사가 규칙 기반 수준에서 이미 작동함을 보인다.

이상의 예비 결과들은 모두 규칙·소규모 수준이지만, 데이터로 학습하기 전 단계에서 이미 방향이 옳음을 자체 실행으로 확인해 준다. 본 고도화는 이 출발점 위에서 실제 시청각 데이터로 각 축을 정밀화한다.

제 3 장

고도화 방안

본 장은 열한 개 고도화 축을 순서대로 서술한다. 각 축은 공유 백본(A) 위에서 연결되며, 축마다 현황과 문제, 방법, 산출물 또는 한계를 함께 밝힌다. 본 계획의 새 기술들은 완성품이 아니라 소규모 프로토타입 수준으로 구현하는 것을 전제한다. 표 6은 열한 축의 목표와 핵심 방법, 주요 자원을 요약한 것이다. 열한 축의 산출 수준은 동일하지 않다. 데이터로 모델을 학습하는 축(A·B·D)은 프로토타입 모델까지, 설계와 근거 마련이 중심인 축(C·E·I)과 안 보이는 소리를 다루는 축(J·K)은 설계와 소규모 실증까지를 이번 단계의 목표로 삼는다.

<표 6> 고도화 축의 요약

축	목표	핵심 방법	주요 자원
A	공유 백본·데이터 확보	정상 발화 변형으로 농인 발화 합성, 자가지도 모델 미세조정	OLKAVS·AV-HuBERT
B	전사 없는 발음채점	강제정렬 기반 GOP 직접 산출, 불확실성 보정, 웹캠 입모양 후기융합	WavLM·MediaPipe
C	채점 근거화·공개 표준	시각 혼동 지각공간 학습, 동구형이음 사전·난이도 지수 공개	시청각 코퍼스
D	입모양 검증	웹캠 52계수 실시간 채점(클라이언트), 단어급 자체 립리딩	MediaPipe·OLKAVS
E	조음 원인 진단	음성·영상에서 조음 역추정, 성도 시뮬레이터 결합	MNGU0·VocalTractLab
F	아바타 시연	투명 두상 내부조음, 실사 아바타와 웹캠 미러링	CC5·3D 성도
G	콘텐츠·개인화	LLM 대량 생성과 검수, 지식추적 기반 개인화	Claude API
H	실전 시나리오	다화자 아바타 대화, 화자 식별과 입모양 동시 읽기	F·G 재사용
I	표준검사	배치·향상도 검사, 지각공간 근거 문항 설계	C 재사용
J	안 보이는 소리 시각 증강	동구형이음 구분에 최소 시각 기호를 없고 실력에 따라 소거	SVG·타임라인

축	목표	핵심 방법	주요 자원
K	입술 너머 조음 단서	텍·볼·목 미세움직임에서 유성·비음 등 자질 신호 추정	MediaPipe· 영상확대

3.1 통합 멀티모달 AI와 농인 발화 합성 (A)

현황과 문제. 농인·난청 화자의 한국어 발화를 담은 대규모 공개 코퍼스는 존재하지 않는다. 대상이 소수 집단이고 발화 수집에 개인정보와 동의 문제가 따르기 때문이다. 데이터가 없으면 아래의 평가 기능(B~E)을 학습할 수 없으므로, 이 부재가 본 고도화의 최대 병목이다.

방법. 정상 발화 시청각 자료(OLKAVS 등)에 조음 교란(포먼트 이동, 말속도 신축, 명료도 저하)과 자기지도 표현 기반 음성 변환을 적용하여 농인 발화의 분포를 근사한 합성 코퍼스를 만든다. 이 합성 자료와 소규모 당사자 파일럿으로 공개 자기지도 모델(음향 표현 WavLM과 시청각 표현 AV-HuBERT)을 미세조정하여, 소리·영상·글자를 함께 표현하는 통합 백본을 구축한다.

구조상 이점. 발음채점(B), 채점 근거화(C), 립리딩(D), 조음 진단(E)이 모두 이 하나의 백본을 공유한다. 축마다 별도의 모델을 처음부터 학습하지 않고 공통 표현 위에 가벼운 기능 계층만 얹으므로, 학습에 드는 연산과 데이터가 절약될 뿐 아니라 여러 기능이 같은 표현을 근거로 삼아 서로 일관된 판단을 내린다는 이점도 있다.

구현. 음향 인코더는 공개 사전학습 가중치(WavLM 계열)를 초기값으로 쓰고 시청각 정합에는 AV-HuBERT를 활용한다. 합성 코퍼스는 OLKAVS를 원천으로 포먼트 이동·시간 신축·명료도 저하를 파라미터화해 생성하며, 소량의 당사자 발화로 보정 계층만 미세조정한다. 학습은 RunPod H100 인스턴스에서 수행하고, 완성된 표현은 하위 축이 공통으로 불러 쓰도록 백엔드에 임베딩 서비스로 상주시킨다. 합성 코퍼스의 충실도가 낮게 확인되면, 합성 데이터 없이 공개 사전학습 가중치를 도메인 적응만 하는 경로로 되돌아가는 폴백을 두어 후속 축이 멈추지 않게 한다.


3.2 전사 비의존 발음채점과 오디오·비주얼 융합 (B)

원리. 전사 단계를 없애고, 목표 음소가 놓일 구간의 음향이 그 음소에 얼마나 부합하는지를 직접 점수화한다. 이 점수가 발음정확도(GOP)이다. 본 계획은 전사를 거치지 않고 농인 발화에 맞추어 산출하는 이 방식을 이하 D-GOP로 부른다. 목표 문장은 시스템이 이미 알고 있으므로 전사가 필요 없다.

음향 채점. 자가지도 음향 표현 위에서 목표 음소열을 강제정렬하여 각 음소의 시간 구간을 정하고, 구간별 음소 사후확률로 정확도를 계산한다. 표준 GOP가 정상 발화를 전제해 농인 발화에 과신하는 문제는, 백본의 도메인 적응과 불확실성 정량화(예측 분산, 최상위 확률과의 여유값)로 보정한다.

영상 융합. 농인은 음성 자체가 불안정한 반면 입모양은 상대적으로 안정적이다. 웹캠에서 얻은 입모양 신호를 음향 점수와 후기 융합하되, 음향이 불확실한 구간일수록 영상의 가중치를 높인다(그림 11). 소리가 흔들리는 대목을 보이는 조음이 받쳐 준다. 이 방향의 타당성은 2.7의 예비 실증에서 공개 음성으로 확인하였다.

구현. 강제정렬은 음소 단위 정렬로 구간을 추정하고 각 구간의 음소 사후확률로 GOP를 산출한다. 불확실성은 예측 분포의 엔트로피와 최상위·차상위 확률의 여유값으로 계산한다. 웹캠 입모양은 프론트에서 MediaPipe Face Landmarker로 초당 약 30프레임의 52개 계수를 추출해 기준 프로파일과의 코사인 유사도를 구하고, 두 점수를 신뢰도 가중으로 합친다. 백엔드는 기존 발화 평가 엔드포인트를 D-GOP 경로로 교체하되 전사 방식을 폴백으로 남긴다.



〈그림 11〉 전사 비의존 오디오·비주얼 발음평가 구조. 음향과 영상을 각각 평가한 뒤 음향 불확실 구간을 입모양으로 보완한다.

3.3 데이터 기반 채점과 공개 표준 리소스 (C)

현황과 문제. 현행 채점의 음운 유사도 행렬과 비침 지속시간은 개발자가 손으로 지정한 상수로, 실제 독화 혼동 빈도나 조음 데이터와 대조된 적이 없다. 채점의 근거가 경험적으로 확립되어 있지 않다.

방법. 공개 한국어 시청각 코퍼스에서 각 음소 구간의 입모양 시퀀스를 표현으로 인코딩하고, 같은 비침은 가깝게 다른 비침은 멀게 배치하는 대조학습으로 시각 혼동을 반영한 지각 공간을 구성한다. 두 음소의 시각 유사도는 이 공간에서의 거리로 정의되며, 이 값이 수작업 계수를 대체한다.

공개 표준. 이 공간에서 채점 계수뿐 아니라 문장의 독화 난이도 지수와 최소대립쌍이 함께 도출된다. 이를 한국어 동구형이음 사전, 독화 난이도 지수, 표준 평가셋으로 정리하여 공개한다. 한국어 독화에는 이러한 표준 자원이 거의 없으므로, 이 자료는 앱 밖의 연구와 교육에서도 활용될 수 있다.

구현. 지각 공간은 각 음소 구간의 입모양 시퀀스를 인코딩해 대조학습으로 임베딩하고, 음소 쌍의 코사인 거리로 유사도 행렬을 산출해 채점 로직의 수작업 계수를

대체한다. 난이도 지수는 문장 구성 음소의 이웃 밀도와 동구형이음 비율로 정의한다. 동구형이음 사전과 평가셋은 판본과 함께 공개 저장소로 배포한다.

3.4 웹캠 입모양 채점과 자체 립리딩 모델 (D)

현황과 문제. 현행 시스템은 아바타로 올바른 입모양을 보여 줄 뿐, 학습자가 그 입모양을 실제로 맞게 만들어 내는지는 확인하지 못한다. 학습자가 스스로 잘 따라 했는지 알 수 없으니, 보고 따라 하고 교정하는 순환, 곧 학습 루프가 닫히지 않는다.

웹캠 채점. 표준 얼굴 계수 52개(blendshape)를 브라우저에서 직접 추출하여 목표 비침의 기준 계수와 코사인 거리로 비교해 실시간으로 채점한다. 영상은 서버로 전송하지 않고 기기 안에서만 처리하므로 사생활이 보호된다.

자체 립리딩. 여기에 더하여 공개 한국어 시청각 코퍼스로 자체 립리딩 모델을 학습하여, 기계가 실제로 입모양을 읽어 단어를 맞히는 검증을 수행한다. 영상만으로 문장 전체를 인식하는 것은 아직 정확도가 낮으므로, 본 계획의 립리딩은 단어 단위 검증과 콘텐츠 정렬 보조로 범위를 한정한다.

구현. 웹캠 채점은 서버 없이 브라우저에서 동작하며 52개 계수와 목표 비침 기준 프로파일을 비교한다. 자체 립리딩 모델은 입술 관심영역을 삼차원 합성곱과 트랜스포머로 인코딩하는 경량 구조로, 공개 코퍼스의 단어 단위 구간으로 학습하고 단어 정확도로 평가한다.

3.5 조음 원인 진단과 조음 시뮬레이터 (E)

현황과 문제. 점수만으로는 무엇을 어떻게 고쳐야 할지 알기 어렵다. 학습자는 자신이 틀렸다는 사실은 알아도, 혀와 입술을 구체적으로 어떻게 움직여야 목표 소리에 가까워지는지는 알지 못한다. 정작 교정의 방향이 빠져 있는 것이다.

조음 역추정. 음성과 영상에서 혀와 입술의 조음 파라미터(혀 높이와 전후 위치, 입술 원순도, 개구도)를 역추정하고, 목표 조음과의 차이를 근거로 “혀를 조금 더 앞으로” 같은 교정을 제공한다. 조음 계측 자료는 한국어 공개본이 없어 영어권 코퍼스(MNGU0, USC-TIMIT)로 대체하며, 이로 인한 차이는 당사자 파일럿으로 보완한다.

시뮬레이터. 오픈소스 성도 시뮬레이터를 결합하여, 학습자가 혀 위치를 직접 조작하면 소리와 입모양이 함께 변하는 인터랙티브 교구를 제공한다. 이 교구는 다음 절의 투명 아바타와 동일한 삼차원 성도 자산을 공유한다.

구현. 조음 역추정은 음향·영상 표현에서 조음 파라미터를 회귀하는 신경망으로 구성하고 MNGU0·USC-TIMIT의 조음-음성 병렬쌍으로 학습한다. 성도 시뮬레이터는 VocalTractLab을 파라미터 인터페이스로 연동해 추정 조음을 성도 형상과 합성음으로 렌더한다.

3.6 실사·투명 아바타 시연 (F)

현황과 문제. 독화가 막히는 근본 이유는 두 가지이다. 하나는 소리를 가르는 결정적 지점이 혀나 목젖처럼 입 안에 있어 밖에서는 보이지 않는다는 점이고, 다른 하나는 같은 말이라도 화자마다 입모양이 달라 낯선 얼굴은 좀처럼 읽히지 않는다는 점이다.

투명 두상과 실사 아바타. 얼굴을 반투명하게 처리하여 혀와 목젖 등 내부 조음을 드러냄으로써 보이지 않는 차이를 눈으로 가르친다. 또 실제 선생님의 얼굴을 실사 아바타로 만들어 그 입모양으로 연습하게 한다. 아바타가 표준 얼굴 계수 규격을 따르므로, 웹캠에서 읽은 사용자의 입모양을 아바타에 그대로 비추는 거울 기능이 자연스럽게 구현된다. 임의 문장의 정확한 립싱크는 상용 음성합성이 내보내는 입모양 계수로 구동한다.

구현. 아바타는 Character Creator 5로 여러 얼굴을 생성해 GLB로 내보내고 three.js에서 morphTargetInfluences로 구동하며, 오픈소스 TalkingHead를 립싱크 구동 엔진으로, NVIDIA Audio2Face를 정답 발음 애니메이션의 오프라인 생성에 활용한다. 립싱크는 상용 음성합성이 내보내는 52개 blendshape 이벤트를 그대로 매핑한다. 투명 두상은 구매한 성도 해부 메시에 자모별 조음 포즈를 shape key로 제작하고 피부 알파를 낮춰 내부를 노출한다. 미리링은 D축이 추출한 계수를 같은 morph target에 연결한다.

3.7 콘텐츠 대량화 및 개인화 (G)

현황과 문제. 현행 커리큘럼은 기초 단계의 콘텐츠 분량이 얇다. 단어 은행 약 24개, 최소대립쌍 약 10개, 문맥 추론 문항 약 5개에 머물러 학습 경로를 충분히 채우지 못한다.

방법. 대규모 언어모델 기반 생성 파이프라인으로 이 콘텐츠를 수백에서 수천 규모로 확장하고, 자동 검토와 사람 검토의 이중 확인으로 품질을 관리한다. 아울러 학습 기록으로 사용자의 음소별 숙달을 추정하는 지식추적을 두어 다음 문항을 개인화한다.

구현. 생성 파이프라인은 Claude API로 단어·최소대립쌍·문맥 문항을 대량 생성하고 규칙 검사와 사람 검토의 이중 게이트로 통과분만 채택한다. 개인화는 학습 로그에서 음소별 정오를 지식추적으로 추정해 다음 문항의 난이도와 표적 음소를 정한다.

3.8 다자 대화·실전 시나리오 독화 (H)

현황과 문제. 실제 대화는 화자가 여럿이고 발화 순서가 수시로 바뀌며, 듣는 사람은 지금 누가 말하고 있는지부터 가려내야 한다. 그러나 현행 훈련은 한 화자의 한 문장씩만 다루어, 이러한 실제 상황과는 거리가 있다.

방법. 여러 화자 아바타가 번갈아 말하는 상황을 재현하여, 누가 말하는지와 그 사람의 입모양을 함께 읽는 실전 독화를 훈련한다. 콘텐츠 대량화(G)가 생성한 문항을 다화자 상황에 배치하고, 립리딩(L)과 문맥 추론을 실전으로 재조합한다. 화자 얼굴은 아바타 도구로 여러 개를 생성하여 화자 다양성을 확보한다.

구현. 서로 다른 아바타 얼굴을 화자별로 배정하고 발화 순서를 타임라인으로 구성한다. 사용자는 각 차례 화자의 입모양을 읽어 응답하고, 채점은 립리딩과 문맥 추론을 결합한다.

3.9 디지털 독화 표준검사 (I)

현황과 문제. 독화 실력을 재는 표준화된 검사가 국내에 없다. 그 때문에 학습자의 현재 수준이 어느 정도인지, 훈련을 거친 뒤 실제로 나아졌는지를 객관적으로 판단할 근거가 마땅치 않다.

방법과 활용. 첫 수준을 진단하는 배치 검사와 향상도를 재는 검사를 표준화하여 디지털 검사도구로 구현하고, 지각 공간과 독화 난이도 지수(C)를 문항 설계의 근거로 삼는다. 개발용 공개 자원(C)과 사용자 대상 검사(I)는 역할이 구분된다. 이 검사도구는 교사와 언어재활사가 학습자의 상태를 객관적으로 파악해 현장에 도입하는 근거가 된다.

구현. 지각 공간과 난이도 지수로 난이도를 통제된 문항 은행에서 적응적으로 출제한다. 배치 검사는 짧은 문항으로 초기 수준을 추정하고 향상도 검사는 동형 문항으로 사전·사후를 비교하며, 결과는 음소별 오류 프로파일로 제공한다.

3.10 안 보이는 소리의 시각 증강 (J)

현황과 문제. 동구형이음은 유성·기식·비음처럼 입술 밖으로 드러나지 않는 자질에서 비롯되어, 입술만으로는 원리적으로 가릴 수 없다. 투명 두상(F)은 입 안을 보여 주지만 촬영된 실제 대화 영상에는 얻을 수 없다는 한계가 있다.

방법. 입술로 드러나지 않는 자질에만 대응하는 최소한의 시각 기호 체계를 설계하여, 구분이 필요한 순간에만 입 근처에 겹쳐 보여 준다. 기호는 임의로 정하지 않고 조음 자질에 대응시킨다. 예컨대 기식은 바람 표시, 비음은 물결, 유성은 채운 점으로 나타낸다. 학습자의 숙달도가 오르면 기호의 빈도와 진하기를 점차 낮추어 소거하고, 끝에는 기호 없이 맨눈 독화로 넘어가게 한다.

근거. 이는 손 모양으로 입술의 사각지대를 보완하는 확립된 방법인 큐드 스피치(Cued Speech, Cornett 1967)를, 손 대신 화면 기호로 자동 생성하고 실력에 따라 소거하도록 재해석한 것이다. 정보를 말과 그림 두 경로로 함께 제시하는 이중부호화 이론과, 보조를 점차 걷어 내는 스캐폴딩·페이딩 학습 원리가 이를 뒷받침한다.

구현. 엔진이 이미 산출하는 음소·비침 타임라인에서 동구형이음 구분이 필요한 프레임을 찾아 그 위에 SVG로 기호를 겹친다. 자질을 기호로 잇는 매핑 표를 두고, 난이도 지수(C)로 표시 우선순위를, 지식추적(G)으로 소거 일정을 정한다. 규칙 기반 오버레이라 촬영된 실제 대화 영상에도 얻을 수 있어 투명 두상(F)이 닿지 못하는 상황을 보완한다. 한국어 조음 데이터가 없어도 착수할 수 있으며, 새 기호의 학습 부담과 소거 후 전이 여부는 당사자 파일럿으로 검증한다.

3.11 입술 너머 확장 조음 단서 (K)

현황과 문제. 웹캠 채점(D)은 입술을 중심으로 본다. 그러나 안 보이는 자질의 흔적은 턱과 볼, 목, 콧방울처럼 얼굴 전체에 남는다. 이 신호를 흘려보내면 앞 절(J)이 표시할 근거도 약해진다.

방법. 웹캠에서 입술뿐 아니라 턱의 개폐, 볼의 팽창, 목과 콧방울 주변의 미세한 움직임까지 특징으로 뽑아, 유성이나 비음처럼 눈에 잘 띄지 않던 자질의 상관 신호를 추정한다. 이렇게 추정한 신호는 앞 절(J)의 기호를 켜는 근거이자 발음채점(B)의 융합 입력으로 함께 쓴다.

근거. 말은 얼굴 전체에 조음의 흔적을 남긴다는 조음음성학의 관찰, 입술 주변의 넓은 영역을 활용하는 최신 립리딩 연구, 그리고 눈에 안 띄는 미세한 움직임을 드러내는 오일러 영상 확대(Eulerian Video Magnification, Wu 외 2012)가 근거가 된다.

구현. MediaPipe의 입술 외 랜드마크(턱·볼·비강 주변)와 선택적 미세움직임 확대 전처리를 거쳐 경량 분류기로 자질을 추정한다. 모든 처리는 브라우저 안에서 이루어져 영상이 밖으로 나가지 않는다. 미세 신호는 조명과 개인 차이에 민감하므로 보조 신호로만 쓰고 당사자 파일럿으로 보정한다.

제 4 장


구현 및 추진 계획

4.1 시스템 아키텍처

본 절은 고도화가 현행 시스템에 어떻게 얹히는지를 정리한다. 백엔드는 기존 FastAPI 구조를 유지하며, 공유 백본(A)을 임베딩 서비스로 상주시키고 그 위에 발음채점, 립리딩, 조음 진단 엔드포인트를 추가한다. 발화 평가 엔드포인트는 전사 방식에서 D-GOP 방식으로 교체하되 전사 경로를 폴백으로 남긴다. 프론트엔드는 기존 three.js 아바타 파이프라인에 웹캠 입모양 추적과 미러링, 투명 두상, 다자 시나리오 화면을 더한다. 학습 로그와 콘텐츠, 검사 상태는 신규 데이터베이스 표로 관리한다. 전체 데이터 흐름은 그림 12와 같고, 새로 추가하거나 교체하는 주요 구성요소는 표 7과 같다.

<표 7> 신규 및 교체 구성요소

구분	구성요소	역할 (관련 축)
백엔드	임베딩 서비스	공유 백본 표현을 하위 축에 제공 (A)
백엔드	발음평가 엔드포인트	D-GOP 산출과 오디오·비주얼 융합 채점 (B)
백엔드	립리딩·조음 진단	단어 단위 립리딩과 조음 역추정 (D·E)
프론트	웹캠 입모양·미러링	52 계수 추적·채점과 아바타 미러링 (D·F)
프론트	투명 두상·시뮬레이터	내부 조음 시연과 조작형 교구 (E·F)
프론트	다자 시나리오	다화자 독화 훈련 화면 (H)
프론트	시각 증강 오버레이	동구형이음 구분 기호 표시와 소거 (J)
프론트	확장 조음 특징 추출	입술 외 얼굴 신호로 자질 추정 (K)
데이터	신규 데이터베이스 표	콘텐츠·검사·개인화 상태 관리 (G·I)



〈그림 12〉 시스템 데이터 흐름. 데이터에서 공유 백본(A)을 거쳐 평가·증강 기능과 학습자 대면으로 이어지고, 성취 검사(I)로 순환한다.

4.2 데이터 및 학습 계획

데이터는 무료 확보 자원을 원천으로 삼는다. 합성 코퍼스는 OLKAVS를 변형하여 구축하고, 조음 학습에는 MNGU0와 USC-TIMIT를 사용한다. 학습 연산은 구매한 RunPod H100 크레딧(약 370시간)을 백본 미세조정, 발음평가 보정 계층, 립리딩 모델, 조음 역추정에 배분한다. 대략적 배분은 백본과 합성에 40퍼센트, 발음평가와 조음에 35퍼센트, 립리딩에 25퍼센트를 기준으로 하되 실험 결과에 따라 조정한다. 평가는 발음평가의 전문가 판정과의 상관, 립리딩의 단어 정확도, 조음 진단의 목표 대비 오차, 그리고 당사자 파일럿의 사전·사후 독화 정확도로 확인한다. 발음채점 자체는 자체 D-GOP로 수행하며, 상용 발음평가(SpeechSuper)는 채점 엔진이 아니라 대조군으로 두어 놓인 발화에서의 상대적 우위를 확인하는 데만 쓴다.

이번 단계의 검증 목표는 프로토타입 수준에 맞추어 탐색적으로 설정한다. 발음평가에서는 전문가 판정과의 순위 상관이 뚜렷한 양의 값을 보이는 것, 단어 단위 립리딩에서는 무작위 수준을 분명히 넘는 정확도에 이르는 것, 당사자 파일럿에서는 학습 전 대비 학습 후 독화 정확도의 향상이 관찰되는 것을 성공의 기준으로 둔다. 이 기준들은 달성 시 후속 연구에서 정량 임계치를 높여 확장한다. 대조군 비교에 필요한 소규모 라벨 평가셋은 당사자 파일럿에서 수집한 발화에 언어재활 자문을 거쳐 구축한다.

4.3 구매 자산 활용 방안

구매 자산은 다음과 같이 활용한다. 표 8은 품목별 구체적 활용을 정리한 것이다.

〈표 8〉 구매 자산의 활용 방안

품목	구체적 활용	관련 축
Character Creator 5	교사 얼굴 여러 개를 생성해 GLB로 내보내 아바타와 다화자 화자로 사용	F·H
Headshot 3	사진에서 실사 얼굴을 만들어 화자 맞춤 아바타를 제작	F
3D 성도 해부 모델	자모별 조음 포즈를 shape key로 제작해 투명 두상과 시뮬레이터에 사용	E·F
RunPod H100	백본 미세조정, 발음평가 보정, 립리딩·조음 학습 연산	A·B·D·E
SpeechSuper	자체 D-GOP의 상용 대비 대조군(벤치마크)	B
Typecast TTS	정답 발음 음성 생성과 아바타 립싱크 구동	F·G
fly.io	다사용자 배포와 학습 로그 수집	운영
Claude Max	콘텐츠 생성·검수, 코칭 문구, 코드·실험 보조	G·전반

4.4 추진 전략 및 단계

추진은 세 단계로 구성한다. 첫 단계는 기반 구축으로, 데이터 확보와 합성 파이프라인 준비, 공유 백본의 도입, 삼차원 자산과 아바타 파이프라인의 구성을 포함한다. 둘째 단계는 핵심 기능의 프로토타이핑으로, 발음채점과 융합, 지각 공간, 웹캠 채점과 립리딩, 조음 진단을 백본 위에 얹는다. 셋째 단계는 통합과 검증으로, 시연·훈련·검사 기능을 결합하고 소규모 파일럿으로 확인한다. 콘텐츠 확장은 전 기간에 걸쳐 병행한다.

열한 개 축이 많아 보이지만 실제 개발 부담은 축의 수만큼 크지 않다. 평가 축(B·C·D·E)은 공유 백본(A) 하나 위에 얹는 기능 계층이고, 실전 시나리오(H)와 표준검사(I)는 앞선 축(F·G·C)의 산출을 재사용하며, 시각 증강(J)은 확장 조음 단서(K)가 캐넌 신호를 표시하는 관계다. 즉 처음부터 새로 만드는 독립 과제는 소수이고 나머지는 공유 자산 위의 파생이다. 다섯 구성원이 서로 다른 축을 병렬로 맡고, 각 단계 끝에 진행 여부를 판단하는 점검점을 두어 일정이 빠듯해지면 파생 축의 산출 수준을 설계·실증으로 낮추어 조정한다. 이로써 넓은 범위를 유지하면서도 완주 가능성을 확보한다.

4.5 추진 일정

전체 기간을 여섯 구간으로 나눈 개략 일정은 표 9와 같다. 전체 사업 기간은 약 6개월로 잡으며, 표의 여섯 구간은 각각 약 1개월에 해당한다.

<표 9> 추진 일정 (● 집중 수행, ○ 병행 수행)

과제 W 구간	1	2	3	4	5	6
기반 구축·데이터 확보	●	●	○			
A 백본·합성 데이터	○	●	●	○		
B 발음채점·융합		●	●	●	○	
C 채점 근거화·공개 표준		○	●	●	○	
D 웹캠 채점·립리딩			○	●	●	○
E 조음 진단·시뮬레이터			○	●	●	
F·G·H 시연·콘텐츠·시나리오	○	○	○	●	●	●
I 표준검사·통합·검증				○	●	●

4.6 추진 체계 및 역할

팀 CNSAi(남윤수·최윤건·나현빈·염우진·황성주)가 개발을 주관하며, 담당은 다음과 같이 나눈다. 남윤수는 총괄과 함께 공유 백본 및 발음평가 모델(A·B)과 시스템 아키텍처를 맡는다. 최윤건은 실사·투명 아바타와 조음 시뮬레이터(E·F)를 담당한다. 나현빈은 프론트엔드와 웹캠 입모양 파이프라인, 다자 시나리오(D·H)를 맡는다. 염우진은 데이터 확보와 농인 발화 합성, 립리딩 학습(A·D)을 담당한다. 황성주는 콘텐츠 대량화와 개인화, 표준검사(G·I)를 맡는다. 당사자 파일럿과 검사도구 타당화에는 언어재활 및 특수교육 분야의 자문과 협력 기관의 도움을 받는다. 촉각 학습기의 물리적 하드웨어 제작은 본 고도화의 범위에 포함하지 않는다. 위 담당은 편의상의 구분이며 구성원은 상호 협력한다. 팀은 현재의 LIPLAB을 직접 구축해 온 실적을 갖추고 있다. 화면 20개 규모의 웹 애플리케이션과 15종 비심 분류 체계, 삼차원 아바타, 13개 데이터베이스 표로 이루어진 학습 시스템을 구현한 경험이 본 고도화의 수행 역량을 뒷받침한다.

4.7 당사자 파일럿 및 연구윤리

본 고도화의 여러 측은 소규모 당사자 파일럿에 기대어 검증된다. 파일럿은 청각장애 당사자 소수와 비당사자 대조군을 대상으로, 학습 전후의 독화 정확도를 동형 검사로 비교하는 설계를 따른다. 참가자 모집과 협력 기관은 특수교육 및 언어재활 현장을 통해 협의 중이며, 확정되는 대로 참가 규모와 절차를 구체화한다.

당사자로부터 수집하는 발화 음성과 얼굴 영상은 민감정보에 해당하고 참가자 상당수가 미성년일 수 있으므로, 연구윤리를 다음과 같이 지킨다. 참가 전에 수집 목적과 이용 범위를 설명하고 본인과 법정대리인의 사전 동의를 받으며, 데이터는 목적에 필요한 최소한만 수집한다. 수집한 자료는 접근을 통제하여 보관하고 정해진 기간이 지나면 파기하며, 합성과 학습에의 이용은 동의 범위 안으로 한정한다. 웹캠 입모양 추적은 영상을 서버로 보내지 않고 기기 안에서만 처리한다. 이 절차는 언어재활 및 특수교육 자문을 거쳐 점검한다.

4.8 위험요인 및 대응

주요 위험요인과 대응 방안은 표 10과 같다.

<표 10> 주요 위험요인 및 대응 방안

위험요인	대응 방안	관련 측
농인 발화 코퍼스 부재	정상 발화 변형으로 합성, 백본만 도메인 적응, 파일럿 보완	A·B
한국어 조음·립리딩 데이터 한계	공개 시청각·영어권 조음 자료로 대체, 단어급으로 범위 한정	D·E
모델 성능의 불확실성	완성이 아닌 프로토타입으로 범위 설정, 영상·시각 되먹임 병행	B·D
생성 콘텐츠의 품질 편차	자동 검토와 사람 검수의 이중 확인	G
개인정보·영상 취급	웹캠 영상의 브라우저 로컬 처리, 최소 수집과 사전 동의	D·F

4.9 보안 취약점 및 대응

본 시스템은 음성과 얼굴, 웹캠 영상 같은 민감·생체 정보를 다루고 학습자 다수가 미성년일 수 있으므로, 개인정보와 보안을 설계 단계에서 함께 다룬다. 주요 취약 영역과 대응은 표 11과 같다.

<표 11> 보안·개인정보 취약점과 대응

취약 영역	위험	대응
생체·개인정보(음성· 얼굴·웹캠)	민감·생체 정보 유출	웹캠 영상은 브라우저에서만 처리하여 서버로 보내지 않고, 음성은 채점 직후 폐기하며 저장을 최소화하고 암호화한다
미성년 학습자 데이터	아동·청소년 개인정보 보호	보호자 동의, 최소 수집, 가명·비식별 처리, 목적 외 사용 금지
전송·저장	도청·유출	전 구간 HTTPS/TLS, 저장 시 암호화, 최소 권한 접근 통제
인증·세션	계정 탈취·세션 하이재킹	비밀번호 해싱, 세션 만료와 CSRF 방지, 민감 동작 재인증
API 키·모델	키 노출과 오남용 과금	키를 서버 비밀로만 보관해 클라이언트 노출 금지, 요청 프록시와 호출 제한
LLM 프롬프트 주입	사용자 입력이 코칭 프롬프트를 오염	입력 검증과 역할 분리, 출력 필터링
배포·의존성(fly.io)	설정 오류·취약 의존성	비밀 주입, 로그의 개인정보 마스킹, 의존성 취약점 정기 점검
열람·삭제권	개인정보보호법 대응	열람·정정·삭제 요청 처리 절차와 보관기간 정책 수립

요약하면 웹캠 영상은 원칙적으로 단말을 벗어나지 않으며, 음성은 채점 목적에 한해 일시적으로만 사용한다. 개인정보 최소 수집과 사전 동의, 삭제권 보장을 기본 원칙으로 두고, 배포 파이프라인에서 비밀 관리와 의존성 점검을 정기적으로 수행한다.

제 5 장

예산 및 조달 계획

5.1 편성 원칙

예산은 하드웨어 구매·제작과 인건비성 지출을 제외하고, 소프트웨어 라이선스, 삼차원 자산, 인공지능 연산, 데이터 확보처럼 구매 형태로 결제되는 항목에만 편성한다. 학습 데이터와 오픈소스 도구는 무료로 확보하여 예산 소요가 없으며, 실지출은 삼차원 자산과 연산, 상용 인공지능 이용에 집중된다. 필수 구매를 채운 뒤 남은 예산은 학습 연산(GPU)을 우선 확보하고, 그다음 몫을 개발 생산성을 위한 인공지능 구독에 편성한다.

5.2 구매 명세

구체적 구매 명세는 표 12와 같다. 환율은 미화 1달러당 1,400원으로 가정하였으며, 단가와 환율은 결제 시점에 따라 달라질 수 있다. 각 품목의 구매처와 구매 방법은 표 아래에 정리한다.

<표 12> 구매 명세 (예산 조달 계획)

품목	제품·사양	단가	금액(원)
Character Creator 5	영구 라이선스 1	US\$299	419,000
Headshot 3 플러그인	영구 1 (CC5 필요)	US\$199	279,000
3D 성도 해부 모델	혀·후두·시상단면 3점	US\$207	290,000
GPU 연산 크레딧	RunPod H100 약 370 시간	US\$737	1,032,000
SpeechSuper 발음채점	종량 초기 충전	US\$40	56,000
한국어 TTS	Typecast API	US\$30	42,000
호스팅	fly.io 선불 크레딧	US\$30	42,000
Claude Max 20x	3 계정·개월 (동시 사용)	US\$200/계정·월	840,000
합계		약 US\$2,152	3,000,000

품목별 구매처 및 구매 방법

- **Character Creator 5 (표준·영구)** reallusion.com/plan-and-pricing/individual/perpetual | 계정 로그인 후 카드·PayPal 일시결제. ARKit 페이셜 프로파일과 GLB 익스포트 기본 포함(상위 에디션 불필요). CC4는 단종되어 CC5로 대체됨.
 - **Headshot 3 (플러그인)** reallusion.com/character-creator/headshot | 일시결제. CC5가 설치돼 있어야 동작하는 add-on.
 - **혀 모델: Tongue Rig (\$59)** turbosquid.com/3d-models/tongue-rig-maya-3d-model-1763796 | TurboSquid 일시결제. Standard(로열티프리), FBX/OBJ를 glTF로 변환해 사용.
 - **후두·성대: Larynx and trachea (\$49)** cgtrader.com/3d-models/science/medical/larynx-and-trachea | CGTrader 일시결제. GLB 포함. 로열티프리(no AI)이므로 화면 표시용으로만 사용.
 - **성도 시상단면: Head Cross-Section (\$99)** cgtrader.com/3d-models/science/medical/realistic-human-head-cross-section-anatomy-3d-medical-model | CGTrader 일시결제. glTF 포함, 로열티프리.
 - **GPU: RunPod H100** runpod.io/pricing | 콘솔 Billing에서 선불 크레딧 충전(최소 US\$10, 카드). H100 PCIe 시간당 약 US\$1.99.
 - **SpeechSuper 발음채점** speechsuper.com/pricing.html | 종량제(월 최소 US\$20), 한국어 지원, 요청 수 기준 후청구.
 - **Typecast TTS** typecast.ai/pricing/api | API 구독(Lite 월 US\$15) 또는 스튜디오 구독. 한국어·상업 라이선스 포함.
 - **fly.io 호스팅** fly.io/docs/about/pricing | 카드 등록 또는 선불 크레딧(최소 US\$25). 머신 초 단위 종량제.
 - **Claude Max 20x** claude.com/pricing | claude.ai 계정에서 월간 구독(US\$200/월, 카드).
- 가격·환율은 결제 시점에 변동될 수 있으며, 3D 모델의 세일가 적용 시 여유분은 GPU 크레딧으로 이전한다.

5.3 Claude Max 배정

남는 예산은 학습 연산을 먼저 넉넉히 확보한 뒤, 그 다음 몫을 개발 생산성을 위한 인공지능 구독에 배정한다. 연산과 구독은 성격이 다르다. 연산은 모델을 실제로 학습시키는 필수 자원이고, 구독은 구현과 실험의 반복 속도를 높이는 보조 자원이다. 그래서 GPU 크레딧을 최우선으로 잡고, Claude Max 20x 구독은 그 다음에 편성한다. 이 구독은 한 계정을 여러 달 길게 쓰기보다, 개발이 집중되는 기간에 여러 구성원이 동시에 사용하는 복수 계정 방식으로 운용하며, 본 편성은 모두 3 계정·개월 분량이다. 예컨대 두세 명이 한 달 남짓 함께 쓰는 식이다. 용도는 콘텐츠 생성과 검수, 코칭 문구 작성, 코드 작성과 실험 보조이다. 실험 과정에서 연산이 더 필요하면 삼차원 자산의 세일가 적용 등으로 확보한 여유분을 GPU 크레딧으로 추가한다.

5.4 무료 확보 자원 및 집행 우선순위

아래 자원은 신청 또는 오픈소스로 무료 확보하여 예산 소요가 없다. 한국어 시청각 코퍼스(OLKAVS, KMSAV, AI Hub), 비정형 발화 자료(Speech Accessibility Project), 조음 계측 자료(MNGU0, USC-TIMIT), 성도 시뮬레이터(VocalTractLab), 얼굴 애니메이션 도구(NVIDIA Audio2Face), 립싱크 엔진(TalkingHead), 웹캠 입모양 추적(MediaPipe), 음성 표현 모델(WavLM, wav2vec2), 발화 합성 도구(RnV, Coqui)가 이에 해당한다. 집행은 백본과 발음채점, 그리고 검사·시연에 필요한 삼차원 자산에 우선순위를 둔다.

제 6 장

기대효과 및 활용 방안

6.1 학술적·기술적 기여

본 고도화는 전사에 의존하지 않는 멀티모달 발음·독화 평가라는 방향을, 접근성 문제와 결합한 구체적 설계로 제시한다. 정상 발화를 전제하는 표준 발음평가가 정작 발음 훈련이 가장 필요한 화자에게서 취약해진다는 역설을 드러내고, 음향과 영상을 융합한 대안을 프로토타이핑한다. 또한 수작업 상수에 머물던 독화 채점의 근거를 데이터로 옮기고, 한국어 동구형이음 사전과 독화 난이도 지수, 표준 평가셋, 표준 검사도구를 마련한다. 그동안 없던 한국어 독화의 경험적 근거를 만드는 작업이다.

6.2 사회적 가치

독화를 체계적으로 배울 정규 과정이 없는 상황에서, LIPLAB은 일반학교에 재학하는 청각장애 학습자가 시간과 장소의 제약 없이 스스로 훈련할 수 있게 하는 것을 목표로 한다. 당사자 파일럿을 통해 실제 사용자에게서 효과를 확인함으로써, 접근성 도구가 흔히 놓치는 당사자 검증의 공백을 메운다.

6.3 확장 및 지속 방안

프로토타입에서 확인한 설계는 후속 연구에서 코퍼스를 확대하여 본격적인 성능 개선으로 이어질 수 있다. 축적된 콘텐츠와 학습 로그, 그리고 공개한 표준 자원은 개인화의 정밀도를 높이고 외부 연구·교육과 연계되는 자산이 된다. 협력 기관과 연계하여 검증 규모를 넓히고, 공개한 자원과 검사도구를 후속 연구와 교육에서 쓸 수 있게 한다.

확장 활동 계획. 확장은 세 방향으로 추진한다. 첫째, 대상 확장으로 농·난청 학습자에서 출발하여 발음·언어재활이 필요한 일반 사용자와 노년 청력저하 계층까지 넓힌다. 둘째, 자원 개방으로 한국어 동구형이음 사전과 독화 난이도 지수, 표준 평가셋을 공개 저장소로 배포하여 앱 밖의 연구와 교육에서 재사용되게 하고, 채점과 검사 기능을 공개 인터페이스로 제공한다. 셋째, 현장 연계로 특수학교와 복지관, 언어재활 기관과

협력하여 파일럿과 검증 규모를 넓히고, 확보한 표준 자원을 발판으로 다른 언어로의 이식 가능성을 검토한다.

참 고 문 헌

- 국립특수교육원. (2020). 특수교육통계. 충남: 국립특수교육원.
- 국립국어원. (2023). 한국수어 활용 실태 조사. 서울: 국립국어원.
- Witt, S. M., & Young, S. J. (2000). Phone-level pronunciation scoring and assessment for interactive language learning. *Speech Communication*, 30(2-3), 95-108.
- Yeo, E. J., Choi, K., Kim, S., & Chung, M. (2023). Speech intelligibility assessment of dysarthric speech by using goodness of pronunciation with uncertainty quantification. In *Proceedings of Interspeech 2023*.
- Baevski, A., Zhou, H., Mohamed, A., & Auli, M. (2020). wav2vec 2.0: A framework for self-supervised learning of speech representations. In *Advances in Neural Information Processing Systems (NeurIPS)*.
- Shi, B., Hsu, W.-N., Lakhotia, K., & Mohamed, A. (2022). Learning audio-visual speech representation by masked multimodal cluster prediction (AV-HuBERT). In *International Conference on Learning Representations (ICLR)*.
- Park, J., et al. (2023). OLKAVS: An open large-scale Korean audio-visual speech dataset. *arXiv:2301.06375*.
- McGurk, H., & MacDonald, J. (1976). Hearing lips and seeing voices. *Nature*, 264, 746-748.
- Deci, E. L., & Ryan, R. M. (2000). The “what” and “why” of goal pursuits: Human needs and the self-determination of behavior. *Psychological Inquiry*, 11(4), 227-268.
- Pimperton, H., et al. (2019). Computerized speechreading training for deaf children: A randomized controlled trial. *Journal of Speech, Language, and Hearing Research*, 62(8), 2882-2894.
- Ren, Y., et al. (2021). PTeacher: A computer-aided personalized pronunciation training system with exaggerated audio-visual corrective feedback. *arXiv:2105.05182*.
- Cornett, R. O. (1967). Cued speech. *American Annals of the Deaf*, 112(1), 3-13.
- Wu, H.-Y., Rubinstein, M., Shih, E., Guttag, J., Durand, F., & Freeman, W. (2012). Eulerian video magnification for revealing subtle changes in the world. *ACM Transactions on Graphics*, 31(4).
- Google. (2024). MediaPipe Face Landmarker. Google AI Edge Documentation.

ABSTRACT

Advancing LIPLAB, a Korean Speechreading Learning Platform, Centered on Transcription-free Multimodal Pronunciation and Speechreading Assessment

LIPLAB is a web-based platform that helps deaf and hard-of-hearing learners practice Korean speechreading and speech production. Its current speech-assessment pipeline depends on automatic speech recognition (ASR) transcription, which is structurally paradoxical because the very users of this feature are the speakers whom ASR, trained on typical speech, tends to misrecognize.

This plan reconstructs the system to assess pronunciation and articulation directly from audio and video without a transcription step. It defines eleven axes: a shared multimodal backbone with synthesized deaf speech (A); transcription-free pronunciation scoring with audio-visual fusion (B); data-grounded scoring and an open standard resource (C); webcam mouth-shape scoring and an in-house lipreading model (D); articulatory error diagnosis and a vocal-tract simulator (E); realistic and transparent teacher avatars (F); large-scale content generation and personalization (G); multi-speaker conversational scenarios (H); a digital standardized speechreading test (I); a minimal visual overlay for the sounds that are invisible on the lips (J); and the extraction of articulatory cues beyond the lips (K). Together these connect development, training, and assessment.

Resources concentrate on software, 3D assets, artificial-intelligence computation, and data, excluding hardware fabrication and labor costs. The goal is to advance LIPLAB into an empirically grounded learning tool in the underserved area of Korean speechreading education.

Key words: speechreading, pronunciation assessment, GOP, audio-visual fusion, deaf and hard-of-hearing, self-supervised learning, accessibility